OpenDataCopilot : Chatbot RAG Multi-Domaines

Santé Publique & Pollution Atmosphérique – Comparaison de 4 Architectures RAG, 3 LLMs et 4 Embeddings

Adjimon VITOFFODJI
Master 2 MIASHS – Université de Montpellier Paul Valéry adjimon.vitoffodji@etu.univ-montp3.fr

1. Contexte & Enjeux

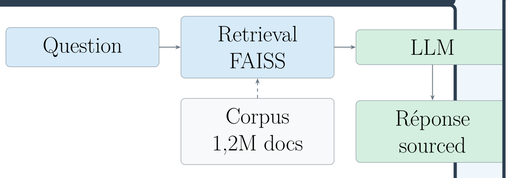

Problématique :

- Données publiques hétérogènes (santé + air)
- Tolérance zéro aux hallucinations
- Nécessité de données temps réel

Sources	SPF, ODISSE, Airparif, OpenAQ
Période	2019–2023 + temps réel
Corpus	1 222 802 documents
Dataset	70 questions annotées

2. État de l'Art RAG

Technique	Avantage
Dense (FAISS)	Sémantique contextuelle
Sparse (BM25)	Correspondance mots-clés
Hybride	Combiné – notre choix
Reranking	Précision accrue

Positionnement : Aucun travail antérieur ne compare systématiquement RAG *et* LLMs sur données santé publique françaises open data.

Contribution :

- 4 architectures validées / 70 questions
- 3 LLMs : GPT-3.5, Mistral 7B, Llama3
- 4 modèles d'embeddings évalués
- Prototype hybride temps réel

3-a. Méthodologie — Architectures & Modèles

1. Baseline
LLM seul, sans contexte

↓

2. RAG Basic
FAISS dense + GPT-3.5

↓

3. RAG Optimisé
BM25+FAISS + Reranking

↓

4. RAG Spécialisé
CamemBERT médical

Modèles testés :

- *Embeddings :* OpenAI `text-emb-3-small`, Sentence-CamemBERT, Solon, CamemBERT-bio
- *LLMs :* GPT-3.5-turbo, Mistral 7B (Ollama), Llama3 8B (Ollama)… *(suite col. 2)*

3-b. Méthodologie — Modèles & Protocole

Modèles testés (suite) :

- *LLMs (suite) :* BioMistral 7B
- *Reranker :* cross-encoder MiniLM-L-6-v2

Protocole : 70 questions stratifiées × 4 architectures, évaluation automatisée sur qualité (utilité jury), pertinence FAISS, taux d'hallucination, latence et coût par question.

4. Corpus & Évaluation

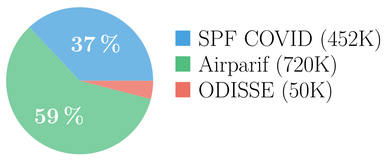

Total : 1 222 802 documents (2019–2023)

Catégorie de questions	N
Santé (COVID, vaccination, épidémio.)	30
Qualité de l'air (NO_2, PM_{10}, O_3)	20
Corrélations santé–pollution	20
Total	**70**

Métriques : Qualité (utilité jury), pertinence FAISS, taux d'hallucination, latence, coût/question.

5. Résultats – Comparaison

Architecture	Qualité	Lat.	Coût/Q	
Baseline	0.300	1.8 s	$0.006	×
RAG Basic	0.743	2.9 s	$0.091	✓
RAG Optimisé	0.754	5.0 s	$0.103	⋆
RAG Spécialisé	0.706	9.4 s	$0.117	×
Mistral 7B	**0.757**	**3.1 s**	**$0.0002**	⋆⋆
Llama3 8B	0.760	4.5 s	$0.0002	✓

Hallucinations : 0 % | Sources citées : 100 %
validé sur 70 questions, 4 architectures

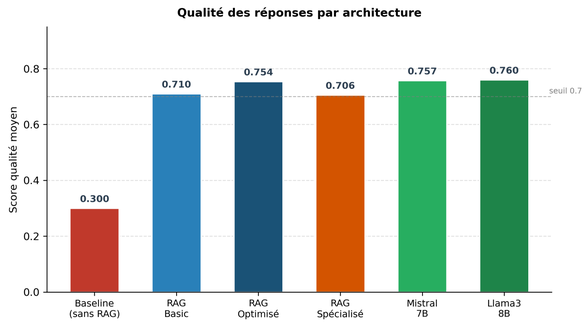

8. Évaluation Critique

Réussites :

- Comparaison rigoureuse 4 architectures / 3 LLMs
- 6 découvertes scientifiques validées
- 0 % hallucination sur toutes architectures
- Prototype hybride temps réel fonctionnel

Difficultés :

- Problème de RAM, GPU (Résolu utilisé machine virtuelle)
- Spécialisation médicale inefficace (−5 %)

Apprentissages : Architecture RAG, évaluation LLM, APIs open data, infrastructure Ollama locale.

6. Découvertes Scientifiques

1. Diversité > Volume : +114 % docs = +18.9 % pertinence seulement

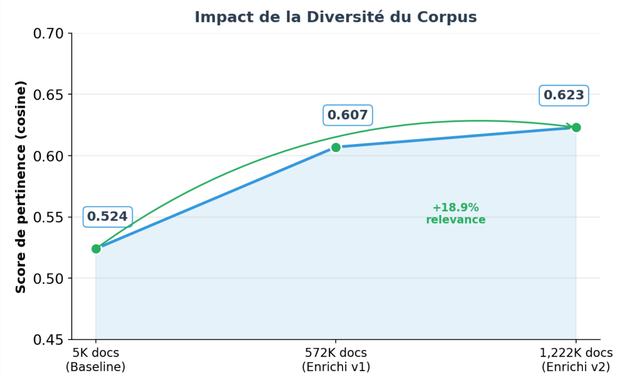

2. Open-source compétitif : Mistral 7B ≈ GPT-3.5, ×500 moins cher

3. Complexité ≠ Performance : sur-ingénierie −6 % qualité

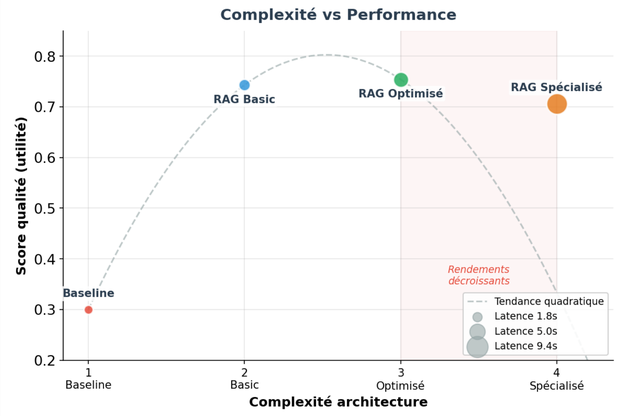

4. Tâche > Domaine : OpenAI généraliste > CamemBERT-bio (−78 %)

Comparaison Modèles d'Embeddings

Modèle	Gap moyen	vs OpenAI
OpenAI text-emb-3-small	0.622	référence
Sentence-CamemBERT	0.527	−4.6 %
Solon	0.467	−24.9 %
CamemBERT-bio	0.137	−78.0 %

5. RAG = 0 % hallucination ·
6. 20→70 questions révèle les vraies performances

Démonstration Système

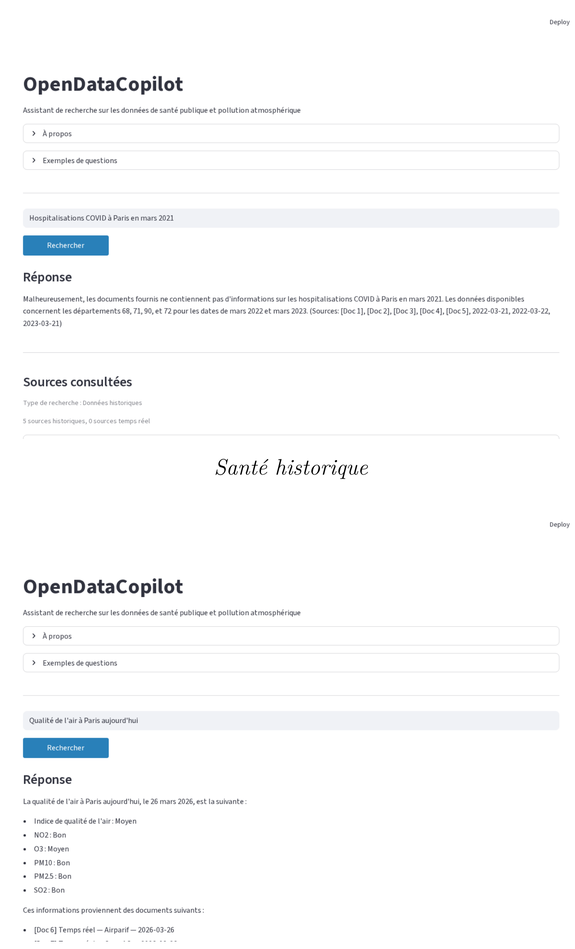

Santé historique

Pollution temps réel – Île-de-France

Fiabilité système : Interface conçue pour fusionner données historiques et temps réel sans hallucination. **0 % confabulation** validé sur l'ensemble des tests.

7. Prototype Hybride Temps Réel

Architecture Système

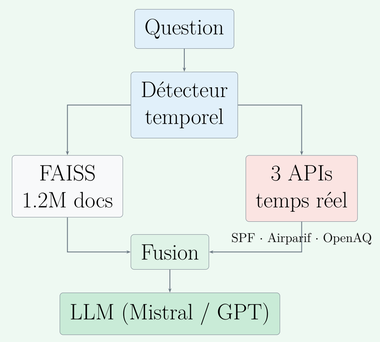

Composant	Tests	OK
Détection temporelle	19/19	✓
APIs temps réel	3/3	✓
Cache (×4 perf.)	pass	✓
Fusion hist. + RT	3/3	✓
Interface Streamlit	pass	✓

Démonstration Interface

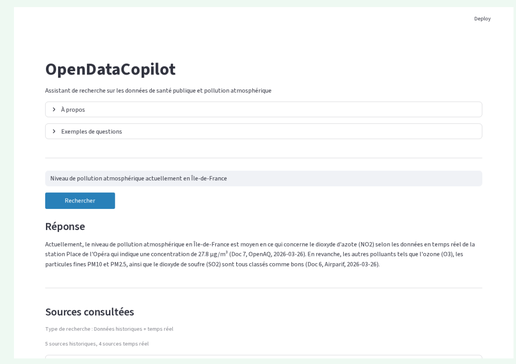

Pollution temps réel – Île-de-France

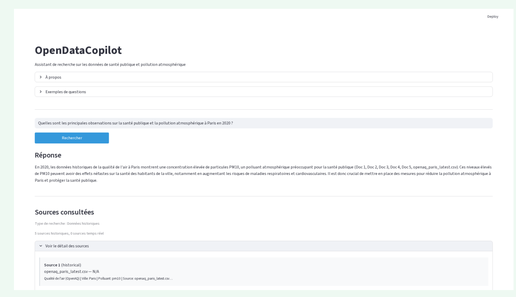

Fusion domaines : santé + pollution

Validation 0 % hallucination
Question hors base → aveu d'ignorance

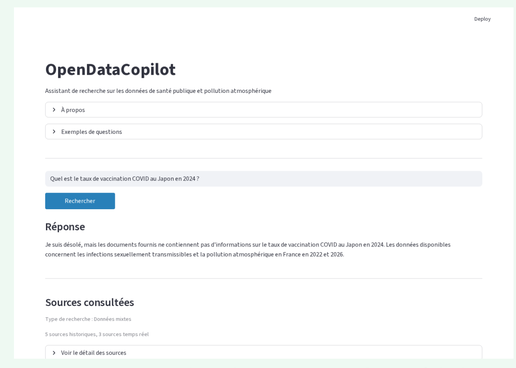

Japon 2024 : système honnête, pas de confabulation

9. Perspectives

Court terme : Déploiement Docker, fine-tuning Mistral-FR

Long terme : Multi-hop reasoning, extension domaines

Système Recommandé

RAG Optimisé + Mistral 7B

Qualité : **0.757** Coût : **$0.0002/Q**
Latence : **3.1 s** Hallucinations : **0 %**
Déploiement local RGPD-compliant