


1. Contexte & Enjeux



Problématique :

- Données publiques hétérogènes (santé + air)
- Tolérance zéro aux hallucinations
- Nécessité de données temps réel

Sources SPF, ODISSE, Airparif, OpenAQ

Période 2019–2023 + temps réel

Corpus 1 222 802 documents

Dataset 70 questions annotées

2. État de l'Art RAG


Technique	Avantage
Dense (FAISS)	Sémantique contextuelle
Sparse (BM25)	Correspondance mots-clés
Hybride	Combiné – notre choix
Reranking	Précision accrue

Positionnement : Aucun travail antérieur ne compare systématiquement RAG *et* LLMs sur données santé publique françaises open data.

Contribution :

- 4 architectures validées / 70 questions
- 3 LLMs : GPT-3.5, Mistral 7B, Llama3
- 4 modèles d'embeddings évalués
- Prototype hybride temps réel

3-a. Méthodologie - Architectures & Modèles



Modèles testés :

- Embeddings** : OpenAI `text-emb-3-small`, Sentence-CamemBERT, Solon, CamemBERT-bio
- LLMs** : GPT-3.5-turbo, Mistral 7B (Ollama), Llama3 8B (Ollama)... (*suite col. 2*)


3-b. Méthodologie - Modèles & Protocole

Modèles testés (suite) :

- LLMs (suite)** : BioMistral 7B
- Reranker** : cross-encoder MiniLM-L-6-v2

Protocole : 70 questions stratifiées × 4 architectures, évaluation automatisée sur qualité (utilité jury), pertinence FAISS, taux d'hallucination, latence et coût par question.

4. Corpus & Évaluation



Total : 1 222 802 documents (2019–2023)


Catégorie de questions	N
Santé (COVID, vaccination, épidémiologie...)	30
Qualité de l'air (NO ₂ , PM ₁₀ , O ₃)	20
Corrélations santé-pollution	20
Total	70

Métriques : Qualité (utilité jury), pertinence FAISS, taux d'hallucination, latence, coût/question.

5. Résultats – Comparaison

Architecture	Qualité	Lat.	Coût/Q	
Baseline	0.300	1.8s	\$0.006	×
RAG Basic	0.743	2.9s	\$0.091	✓
RAG Optimisé	0.754	5.0s	\$0.103	★
RAG Spécialisé	0.706	9.4s	\$0.117	×
Mistral 7B	0.757	3.1s	\$0.0002	★★
Llama3 8B	0.760	4.5s	\$0.0002	✓

Hallucinations : 0 % | **Sources citées : 100 %**
validé sur 70 questions, 4 architectures



8. Évaluation Critique

Réussites :

- Comparaison rigoureuse 4 architectures / 3 LLMs
- 6 découvertes scientifiques validées
- 0% hallucination sur toutes architectures
- Prototype hybride temps réel fonctionnel


Difficultés :

- Problème de RAM, GPU (Résolu utilisé machine virtuelle)
- Spécialisation médicale inefficace (−5%)

Apprentissages : Architecture RAG, évaluation LLM, APIs open data, infrastructure Ollama locale.


6. Découvertes Scientifiques

1. Diversité > Volume : +114% docs = +18.9% pertinence seulement



2. Open-source compétitif : Mistral 7B ≈ GPT-3.5, ×500 moins cher

3. Complexité ≠ Performance : sur-ingénierie −6% qualité



4. Tâche > Domaine : OpenAI généraliste > CamemBERT-bio (−78%)

Modèle	Gap moyen	vs OpenAI
OpenAI text-emb-3-small	0.622	référence
Sentence-CamemBERT	0.527	−4.6 %
Solon	0.467	−24.9 %
CamemBERT-bio	0.137	−78.0 %

5. RAG = 0 % hallucination ·

6. 20→70 questions révèle les vraies performances

Démonstration Système

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Hospitalisations COVID à Paris en mars 2021

Réponse

Malheureusement, les documents fournis ne contiennent pas d'informations sur les hospitalisations COVID à Paris en mars 2021. Les données disponibles concernent les départements 68, 71, 95, et 72 pour les dates de mars 2022 et mars 2023. (Sources: [Doc 1], [Doc 2], [Doc 3], [Doc 4], [Doc 5], 2022-03-21, 2022-03-22, 2023-03-11)

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Qualité de l'air à Paris aujourd'hui

Réponse

La qualité de l'air à Paris aujourd'hui, le 26 mars 2026, est la suivante:

- Indice de qualité de l'air: Moyen
- NO2: Bon
- O3: Moyen
- PM10: Bon
- PM2.5: Bon
- SO2: Bon

Ces informations proviennent des documents suivants:

- [Doc 6] Temps réel - Airparif - 2026-03-26

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Qualité de l'air à Paris aujourd'hui

Réponse

La qualité de l'air à Paris aujourd'hui, le 26 mars 2026, est la suivante:

- Indice de qualité de l'air: Moyen
- NO2: Bon
- O3: Moyen
- PM10: Bon
- PM2.5: Bon
- SO2: Bon

Ces informations proviennent des documents suivants:

- [Doc 6] Temps réel - Airparif - 2026-03-26

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

7. Prototype Hybride Temps Réel

Architecture Système

Question

Détecteur temporel

FAISS 1.2M docs

3 APIs temps réel

Fusion

LLM (Mistral / GPT)

Composant	Tests	OK
Détection temporelle	19/19	✓
APIs temps réel	3/3	✓
Cache (×4 perf.)	pass	✓
Fusion hist. + RT	3/3	✓
Interface Streamlit	pass	✓

Démonstration Interface

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Recherche de pollution atmosphérique actualisée en Île-de-France

Réponse

Actualisation: Le niveau de pollution atmosphérique en Île-de-France est mesuré en continu grâce au dispositif de surveillance de la qualité de l'air (SQA) de l'Agence de l'air Île-de-France. Les données sont mises à jour en temps réel. Les particules fines (PM2.5) ont augmenté de 15% par rapport à la veille, ce qui est classé comme bon. (Sources: [Doc 1], [Doc 2], [Doc 3], [Doc 4], [Doc 5], 2026-03-26)

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

Pollution temps réel – Île-de-France

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Recherche de pollution atmosphérique actualisée en Île-de-France

Réponse

Actualisation: Le niveau de pollution atmosphérique en Île-de-France est mesuré en continu grâce au dispositif de surveillance de la qualité de l'air (SQA) de l'Agence de l'air Île-de-France. Les données sont mises à jour en temps réel. Les particules fines (PM2.5) ont augmenté de 15% par rapport à la veille, ce qui est classé comme bon. (Sources: [Doc 1], [Doc 2], [Doc 3], [Doc 4], [Doc 5], 2026-03-26)

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

Fusion domaines : santé + pollution

Validation 0 % hallucination

Question hors base → aveu d'ignorance

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Rechercher

Quel est le taux de mortalité COVID au Japon en 2024 ?

Réponse

Je suis désolé, mais les documents fournis ne contiennent pas d'informations sur le taux de mortalité COVID au Japon en 2024. Les données disponibles concernent les départements 68, 71, 95, et 72 pour les dates de mars 2022 et mars 2023. (Sources: [Doc 1], [Doc 2], [Doc 3], [Doc 4], [Doc 5], 2022-03-21, 2022-03-22, 2023-03-11)

Sources consultées

Type de recherche: Données historiques

Sources: Historiques, Données Temps Réel

Japon 2024 : système honnête, pas de confabulation

9. Perspectives

Court terme : Déploiement Docker, fine-tuning Mistral-FR

Long terme : Multi-hop reasoning, extension domaines

Système Recommandé

RAG Optimisé + Mistral 7B

Qualité : **0.757** Coût : **\$0.0002/Q**
Latence : **3.1s** Hallucinations : **0 %**
Déploiement local RAGD-compliant