


OpenDataCopilot : Chatbot RAG Multi-Domaines

SANTÉ PUBLIQUE & POLLUTION ATMOSPHÉRIQUE – COMPARAISON DE 4 ARCHITECTURES RAG, 3 LLMs ET 4 EMBEDDINGS

Jérôme ADJIMON

Master 2 Data Science MIA SHS – Université Paul Valéry Montpellier 3 – jerome.vitoff@etu.umontpellier.fr

1. Contexte & Enjeux



Problématique :

- Données publiques hétérogènes (santé + air)
- Tolérance zéro aux hallucinations (contexte santé)
- Nécessité de données temps réel

Sources SPF, ODISSE, Airparif, OpenAQ

Période 2019–2023 + temps réel

Corpus 1 222 802 documents

Dataset 70 questions annotées

2. État de l’Art RAG


Technique	Avantage
Dense (FAISS)	Sémantique contextuelle
Sparse (BM25)	Correspondance mots-clés
Hybride	Combiné – notre choix
Reranking	Précision accrue

Positionnement : Aucun travail antérieur ne compare systématiquement architectures RAG *et* LLMs sur données santé publique françaises open data.

Contribution :

- 4 architectures validées / 70 questions
- 3 LLMs comparés (GPT-3.5, Mistral 7B, Llama3)
- 4 modèles d’embeddings évalués
- Prototype hybride temps réel

3. Méthodologie




Modèles testés :

- Embeddings :** OpenAI `text-embedding-3-small`, Sentence-CamemBERT, Solon, CamemBERT-bio
- LLMs :** GPT-3.5-turbo, Mistral 7B (Ollama), Llama3 8B (Ollama), BioMistral 7B
- Reranker :** cross-encoder MiniLM-L-6

Protocole : 70 questions stratifiées × 4 architectures, évaluation automatisée (qualité, latence, coût, hallucinations).

4. Corpus & Évaluation



Total : 1 222 802 documents (2019–2023)


Catégorie de questions	N
Santé (COVID, vaccination, épidémio.)	30
Qualité de l’air (NO ₂ , PM10, O ₃)	20
Corrélations santé–pollution	20
Total	70

Métriques : Qualité (utilité jury), pertinence FAISS, taux d’hallucination, latence, coût/question.

5. Résultats – Comparaison


Architecture	Qualité	Lat.	Coût/Q	
Baseline	0.300	1.8 s	\$0.006	✗
RAG Basic	0.743	2.9 s	\$0.091	✓
RAG Optimisé	0.754	5.0 s	\$0.103	★
RAG Spécialisé	0.706	9.4 s	\$0.117	✗
Mistral 7B	0.757	3.1 s	\$0.0002	★★
Llama3 8B	0.760	4.5 s	\$0.0002	✓

Hallucinations : 0 % | **Sources citées : 100 %** (70 questions)




6. Découvertes Scientifiques

1. Diversité > Volume : +114% docs = seulement +18.9% de pertinence



2. Open-source compétitif : Mistral 7B ≈ GPT-3.5, ×500 moins cher

3. Complexité ≠ Performance : sur-ingénierie contre-productive (−6% qualité)




4. Tâche > Domaine : OpenAI généraliste > CamemBERT-bio (−78%)



Modèle	Gap moyen	vs OpenAI
OpenAI text-emb-3-small	0.622	référence
Sentence-CamemBERT	0.527	−4.6 %
Solon	0.467	−24.9 %
CamemBERT-bio	0.137	−78.0 %

5. RAG = 0 % hallucination validé sur 70 questions · **6. Dataset granulaire :** 20 → 70 questions révèle les vraies performances

7. Prototype Hybride Temps Réel



Composant	Tests	OK
Détection temporelle	19/19	✓
APIs temps réel	3/3	✓
Cache (×4 perf.)	pass	✓
Fusion hist. + RT	3/3	✓
Interface Streamlit	pass	✓



Qualité de l’air – Paris aujourd’hui

8. Évaluation Critique

Réussites :

- Comparaison rigoureuse 4 architectures / 3 LLMs
- 6 découvertes scientifiques validées
- 0 % hallucination – toutes architectures
- Prototype hybride temps réel fonctionnel

Difficultés :

- Bug Git : 2.65 GB → 11 MB (BFG, résolu)
- Spécialisation médicale inefficace (−5%)

Apprentissages : Architecture RAG, évaluation LLM, Git avancé, APIs open data, Ollama (infrastructure locale)

9. Perspectives

Court terme (✓ réalisé) : Prototype + interface Streamlit

Moyen terme : Déploiement Docker, fine-tuning Mistral-FR

Long terme : Multi-hop reasoning, extension domaines