


OpenDataCopilot : Chatbot RAG Multi-Domaines – SANTÉ PUBLIQUE

Jérôme ADJIMON

Master 2 Data Science MIA SHS – Université Paul Valéry Montpellier 3 –
jerome.vitoff@etu.umontpellier.fr

1. Contexte & Enjeux



Problématique :

- Données publiques hétérogènes (santé + air)
- Tolérance zéro aux hallucinations (contexte santé)
- Nécessité de données temps réel (qualité de l'air)

Sources : SPF, ODISSE, Airparif, OpenAQ

Période : 2019–2023 (+ temps réel)

Corpus : 1 222 802 documents

Dataset : 70 questions annotées

2. État de l’Art RAG

Technique

Dense Sémantique (FAISS)

con-textuelle

Sparse Correspondance (BM25)

mots-clés

Hybride Combiné

(notre choix)

Reranking Précision

accrue

Positionnement :

Aucun travail antérieur ne com-

pare systématiquement architec-

tures RAG *et* LLMs sur don-


nées santé publique françaises open

data.

Contribution :

- 4 architectures validées sur 70 questions
- 3 LLMs (GPT-3.5, Mistral 7B, Llama3)
- 4 modèles d’embeddings évalués
- Prototype hybride temps réel

3. Méthodologie




Modèles évalués :

- Embeddings :** OpenAI `text-embedding-3-small`, Sentence-CamemBERT, Solon, CamemBERT-bio
- LLMs :** GPT-3.5-turbo, Mistral 7B (Ollama), Llama3 8B (Ollama), BioMistral 7B
- Reranker :** cross-encoder/ms-marco-MiniLM-L-6-v2

Protocole : 70 questions stratifiées × 4 architectures, évaluation automatisée (qualité, latence, coût, hallucinations)

4. Corpus & Évaluation



Total : 1 222 802 documents — 2019–2023

Catégorie

Santé 30

(COVID,

vaccina-

tion...)

Qualité 20

de l’air

(NO₂,

PM10...)

Corrélation 30

santé–

pollution


Total 70

Métriques : Qualité (utilité jury), Pertinence FAISS, Taux d’hallucination, Latence, Coût par question

5. Résultats — Comparaison Architectures


Architecture	Qualité	Latence	Coût/Q	Verdict
Baseline	0.300	1.8 s	\$0.006	✗
RAG Basic	0.743	2.9 s	\$0.091	✓
RAG Optimisé	0.754	5.0 s	\$0.103	★
RAG Spécialisé	0.706	9.4 s	\$0.117	✗
Mistral 7B	0.757	3.1 s	\$0.0002	★★
Llama3 8B	0.760	4.5 s	\$0.0002	✓

Hallucinations : 0% | Sources citées : 100% (70 questions)




6. Découvertes Scientifiques

1. Diversité > Volume : +114% de documents = seulement +18.9% de pertinence



2. Open-source compétitif : Mistral 7B ≈ GPT-3.5, ×500 moins cher (\$0.00002 vs \$0.0015/Q)

3. Complexité ≠ Performance : Sur-ingénierie contre-productive (−6% qualité)




4. Tâche > Domaine : OpenAI généraliste > CamemBERT-bio (−78% pertinence)

Comparaison Modeles d'Embeddings		
Modele	Gap moyen	vs OpenAI
OpenAI text-emb-3-small	0.622	référence
Sentence-CamemBERT	0.527	−4.6 %
Solon	0.467	−24.9 %
CamemBERT-bio	0.137	−78.0 %

5. RAG = 0% hallucination validé sur 70 questions toutes architectures

6. Dataset granulaire : 20 → 70 questions révèle les vraies performances

7. Prototype Hybride Temps Réel



Composants Résultats

Détection 19/19 ✓

tem-porelle

APIs 3/3 ✓

temps

réel

Cache OK ✓

(×4 ra-

pidité)

Fusion 3/3 ✓


hist. +

RT

Interface OK ✓

Stream-

lit



Interface : pollution temps réel Île-de-France

8. Évaluation Critique

Réussites :

- Comparaison rigoureuse 4 architectures / 3 LLMs
- 6 découvertes scientifiques validées
- 0% hallucination sur toutes architectures
- Prototype temps réel fonctionnel (3 APIs)

Difficultés :

- Bug Git : dépôt 2.65 GB → 11 MB (BFG, résolu)
- Spécialisation médicale : −5% qualité vs généraliste
- Coût API OpenAI : \$0.90 pour 70 questions

Apprentissages : Architecture RAG, évaluation LLM, Git avancé, APIs publiques open data, infrastructure ML locale (Ollama)

9. Perspectives

Court terme (✓ réalisé) : Prototype + interface

Moyen terme : Docker, fine-tuning Mistral-FR, REST API

Long terme : Multi-hop reasoning, extension domaines