


OpenDataCopilot : Chatbot RAG Multi-Domaines

SANTÉ PUBLIQUE & POLLUTION ATMOSPHÉRIQUE – COMPARAISON DE 4 ARCHITECTURES RAG, 3 LLMs ET 4 EMBEDDINGS

Jérôme ADJIMON

Master 2 Data Science MIASHS – Université Paul Valéry Montpellier 3 – jerome.vitoff@etu.umontpellier.fr

1. Contexte & Enjeux



Problématique :

- Données publiques hétérogènes (santé + air)
- Tolérance zéro aux hallucinations (contexte santé)
- Nécessité de données temps réel

Sources SPF, ODISSE, Airparif, OpenAQ

Période 2019–2023 + temps réel

Corpus 1 222 802 documents

Dataset 70 questions annotées

2. État de l’Art RAG


Technique	Avantage
Dense (FAISS)	Sémantique contextuelle
Sparse (BM25)	Correspondance mots-clés
Hybride	Combiné – notre choix
Reranking	Précision accrue

Positionnement : Aucun travail antérieur ne compare systématiquement architectures RAG *et* LLMs sur données santé publique françaises open data.

Contribution :

- 4 architectures validées / 70 questions
- 3 LLMs : GPT-3.5, Mistral 7B, Llama3
- 4 modèles d’embeddings évalués
- Prototype hybride temps réel

3. Méthodologie




Modèles testés :

- Embeddings :** OpenAI `text-embedding-3-small`, Sentence-CamemBERT, Solon, CamemBERT-bio
- LLMs :** GPT-3.5-turbo, Mistral 7B (Ollama), Llama3 8B (Ollama), BioMistral 7B
- Reranker :** cross-encoder MiniLM-L-6

Protocole : 70 questions × 4 architectures, évaluation automatisée : qualité, latence, coût, hallucinations.

4. Corpus & Évaluation



Total : 1 222 802 documents (2019–2023)

Catégorie de questions	N
Santé (COVID, vaccination, épidémio.)	30
Qualité de l’air (NO ₂ , PM ₁₀ , O ₃)	20
Corrélations santé–pollution	20
Total	70

Métriques : Qualité (utilité jury), pertinence FAISS, taux d’hallucination, latence, coût/question.

8. Évaluation Critique

Réussites :

- Comparaison rigoureuse 4 architectures / 3 LLMs
- 6 découvertes scientifiques validées
- 0% hallucination sur toutes architectures
- Prototype hybride temps réel fonctionnel

Difficultés :


- Bug Git : 2.65 GB → 11 MB (BFG, résolu)
- Spécialisation médicale inefficace (–5%)

Apprentissages : Architecture RAG, évaluation LLM, Git avancé, APIs open data, infrastructure Ollama locale.

5. Résultats – Comparaison


Architecture	Qualité	Lat.	Coût/Q	
Baseline	0.300	1.8 s	\$0.006	✗
RAG Basic	0.743	2.9 s	\$0.091	✓
RAG Optimisé	0.754	5.0 s	\$0.103	★
RAG Spécialisé	0.706	9.4 s	\$0.117	✗
Mistral 7B	0.757	3.1 s	\$0.0002	★★
Llama3 8B	0.760	4.5 s	\$0.0002	✓

Hallucinations : 0 % | Sources citées : 100 %
validé sur 70 questions, 4 architectures




6. Découvertes Scientifiques

1. Diversité > Volume : +114% docs = +18.9% pertinence seulement



2. Open-source compétitif : Mistral 7B ≈ GPT-3.5, ×500 moins cher

3. Complexité ≠ Performance : sur-ingénierie –6% qualité



4. Tâche > Domaine : OpenAI généraliste > CamemBERT-bio (–78%)

5. RAG = 0 % hallucination · 6. 20→70 questions révèle les vraies performances

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Recherche

Réponse

Hallucinement, les documents fournis ne contiennent pas d'informations sur les hospitalisations COVID à Paris en mars 2021. Les données disponibles concernent les départements 68, 76, 91 et 92 pour les dates de mars 2022 et mars 2023. (Source [Doc 1], [Doc 2], [Doc 3], [Doc 4], [Doc 5], 2022-03-01, 2023-03-01, 2023-03-01)

Sources consultées

Type de recherche : Recherche historique

Source historique : Recherche historique

Santé historique – COVID hospitalisations

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Recherche

Réponse

La qualité de l'air à Paris aujourd'hui, le 20 mars 2026, est la suivante :

Indice de qualité de l'air - Météo

• NO2 : Bon

• O3 : Moyen

• PM10 : Bon

• PM2.5 : Bon

• IZ02 : Bon


Ces informations proviennent des documents suivants :

[Doc 1] Temps réel – Airparif – 2026-03-20

...

Qualité de l'air temps réel – Paris

7. Prototype Hybride Temps Réel



Composant	Tests	OK
Détection temporelle	19/19	✓
APIs temps réel	3/3	✓
Cache (×4 perf.)	pass	✓
Fusion hist. + RT	3/3	✓
Interface Streamlit	pass	✓

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Recherche

Réponse

Actuellement, le niveau de pollution atmosphérique en Île-de-France est mesuré en ce qui concerne le dioxyde d'azote (NO2) selon les données en temps réel de la Station Flux de l'Île-de-France qui mesure une concentration de 278 µg/m³ (Doc 1, OpenAQ, 2026-03-20). En moyenne, les autres polluants tels que l'ozone (O3), les particules fines PM10 et PM2.5, ainsi que le dioxyde de soufre (SO2) sont tous classés comme bons (Doc 6, Airparif, 2026-03-20).

Sources consultées

Type de recherche : Recherche historique + temps réel

Source historique : Recherche historique

Pollution temps réel – Île-de-France

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Recherche

Réponse

Il n'est pas possible de répondre à la question posée sur la corrélation entre la pollution NO2 et les hospitalisations respiratoires à Paris uniquement avec les documents fournis, car ces derniers ne contiennent pas d'informations sur les hospitalisations respiratoires. Les données fournies se limitent à la qualité de l'air mesurée par le polluant NO2 à Paris, sans lien direct avec les hospitalisations respiratoires.

Il serait nécessaire de disposer de données supplémentaires sur les hospitalisations respiratoires à Paris pour pouvoir établir une corrélation entre la pollution NO2 et les hospitalisations.

Source

[Doc 1] [Doc 1] Historique – openaq_paris, latest – N/A

Fusion santé + pollution (corrélation NO₂)

Validation 0 % hallucination
Question hors base → aveu d'ignorance

OpenDataCopilot

Assistant de recherche sur les données de santé publique et pollution atmosphérique

À propos

Exemples de questions

Recherche

Réponse

Quel est le taux de vaccination COVID au Japon en 2024 ?

Recherche

Réponse

Je suis désolé, mais les documents fournis ne contiennent pas d'informations sur le taux de vaccination COVID au Japon en 2024. Les données disponibles concernent les hôpitaux respiratoires, l'openaq_paris et la pollution atmosphérique en France en 2024-03-20.

Sources consultées

Type de recherche : Recherche historique

Source historique : Recherche historique

Nous ne trouvons pas de sources

Japon 2024 : système honnête, pas de confabulation

9. Perspectives

Court terme (✓) : Prototype + interface Streamlit

Moyen terme : Déploiement Docker, fine-tuning Mistral-FR

Long terme : Multi-hop reasoning, extension domaines

Système Recommandé
RAG Optimisé + Mistral 7B
Qualité : **0.757** Coût : **\$0.0002/Q**
Latence : **3.1 s** Hallucinations : **0 %**
Déploiement local RAGPD-compliant